

Grupo de Pesquisas em Sistemas Inteligentes  
Laboratório de Sistemas Inteligentes  
Escola Superior de Tecnologia  
Universidade do Estado do Amazonas



## *Detecção Inteligente de Retinopatia Diabética com Redes Neurais Convolucionais Profundas*

**Diego Lucena de Medeiros & Elloá B. Guedes**

{*dldm.eng18, ebgcosta*}@uea.edu.br

*XXXIX Simpósio Brasileiro de Telecomunicações e Processamento de Sinais (SBrT 2021)*

# Agenda

- 1 Introdução
- 2 Metodologia
- 3 Resultados
- 4 Considerações Finais
- 5 Agradecimentos

# Introdução

- Retinopatia Diabética (RD) é uma complicação crônica da Diabete Mellitus (DM)
- Uma das principais causas de cegueira em certas populações portadoras de DM
- Estima-se que, após 20 anos, quase todos pacientes com DM Tipo I, e cerca de 60 % dos portadores de DM Tipo II, desenvolvem algum grau de RD

# Introdução

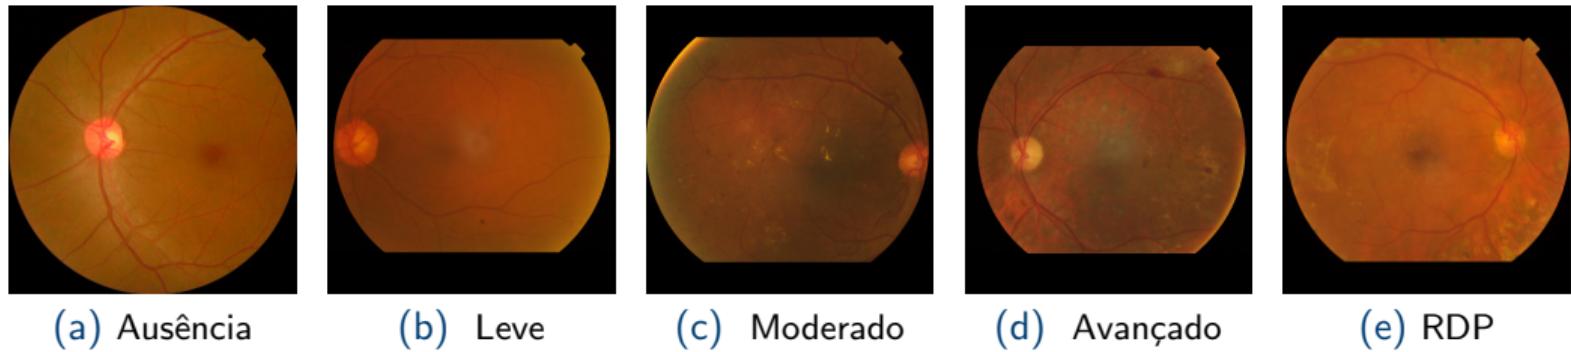


Figura 1: Exemplos de imagens de retina saudáveis e com diversos graus de RD. Os graus leve, moderado e avançado correspondem à RDNP. Fonte: *Aptos Challenge Dataset*.

# Introdução

- Diagnóstico de RD se dá em diversas formas e períodos após o diagnóstico de DM
- Avanços recentes do uso de técnicas de *Deep Learning* na Imagiologia Médica

# Introdução

- Diagnóstico de RD se dá em diversas formas e períodos após o diagnóstico de DM
- Avanços recentes do uso de técnicas de *Deep Learning* na Imagiologia Médica

## Objetivo do Trabalho

Apresentar resultados do uso de Redes Neurais Convolucionais na tarefa de Visão Computacional de detecção do grau de RD a partir de imagens de pacientes coletadas em um contexto real.

# Agenda

- 1 Introdução
- 2 Metodologia
- 3 Resultados
- 4 Considerações Finais
- 5 Agradecimentos

## Metodologia: Dados Experimentais

- Tarefa de classificação multiclasse mediante Aprendizado Supervisionado
- Base de Dados: [Aptos Challenge 2019](#)
  - 3.662 imagens coloridas
  - Rotulada por especialistas
  - Grupo de controle e 4 graus de RD
  - Base de dados desbalanceada



## Metodologia: Dados Experimentais

- Validação Cruzada do tipo *holdout*
  - Treinamento: 70%
  - Validação: 10%
  - Teste: 20%
- Aumento artificial de dados
  - Transformações do tipo espelhamento vertical e horizontal, aumento e cisalhamento

# Metodologia: Modelos, Parâmetros e Hiperparâmetros

- Redes Neurais Convolucionais
- Arquiteturas:
  - LeNet (ReLU e *Leaky ReLU*)
  - AlexNet (ReLU e *Leaky ReLU*)
  - Inception (v3)
  - ResNet-152
- Métricas de desempenho: Acurácia, precisão, revocação e  $F_1$ -Score,

# Agenda

- 1 Introdução
- 2 Metodologia
- 3 Resultados
- 4 Considerações Finais
- 5 Agradecimentos

# Resultados

- Linguagem de programação Python
- *Frameworks* Scikit-learn, Keras, Tensorflow e Matplotlib
- Servidor computacional com processador Intel Core i7 3,7 GHz, 32 GB de memória principal, 960 GB de memória secundária de estado sólido e 2 placas gráficas NVIDIA GTX 1080 Ti com 11 GB cada

# Resultados

Tabela 1: Resultados Experimentais.

|                  | <b>Função</b> | <b>Acurácia</b> | <b>Precisão</b> | <b>Revocação</b> | <b>F<sub>1</sub>-Score</b> | <b>Épocas</b> | <b>Early Stopping</b> | <b>Tempo (s)</b> |
|------------------|---------------|-----------------|-----------------|------------------|----------------------------|---------------|-----------------------|------------------|
| <b>LeNet</b>     | ReLU          | 73,35%          | 66,87%          | 73,35%           | 68,57%                     | 150           | 30                    | 1742             |
| <b>LeNet</b>     | Leaky ReLU    | 73,50%          | 70,31%          | 73,50%           | 70,51%                     | 150           | 25                    | 1776             |
| <b>AlexNet</b>   | ReLU          | 69,16%          | 57,99%          | 69,16%           | 62,13%                     | 100           | 10                    | 560              |
| <b>AlexNet</b>   | Leaky ReLU    | 62,13%          | 70,70%          | 62,13%           | 63,71%                     | 100           | 25                    | 2155             |
| <b>Inception</b> | ReLU          | 78,74%          | 78,49%          | 78,74%           | 75,84%                     | 150           | 20                    | 1666             |
| <b>ResNet</b>    | ReLU          | 73,20%          | 68,98%          | 73,20%           | 67,85%                     | 300           | 20                    | 3795             |

# Agenda

- 1 Introdução
- 2 Metodologia
- 3 Resultados
- 4 Considerações Finais
- 5 Agradecimentos

# Considerações Finais

- Resultados experimentais do uso de CNNs no problema de detecção de RD em imagens médicas
- Aprendizado automático de características como uma das vantagens dos modelos utilizados, sem a necessidade de etapas de pré-processamento
- Mais etapas de avaliação e validação antes de utilização em contextos reais

## Próximos Passos

- Almeja-se explorar outras arquiteturas de CNNs bem como técnicas de otimização e regularização
- Analisar os resultados obtidos em contraste com outras técnicas da literatura

# Agenda

- 1 Introdução
- 2 Metodologia
- 3 Resultados
- 4 Considerações Finais
- 5 Agradecimentos

## Agradecimentos

Os autores agradecem o apoio financeiro e material provido pela Fundação de Amparo à Pesquisa do Estado do Amazonas (FAPEAM) e pelo Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) por meio dos Programas PPP Edital 04/2017 e PAIC 2020/2021.



**FAPEAM**  
FUNDAÇÃO DE AMPARO À PESQUISA  
DO ESTADO DO AMAZONAS  
CERTIFICADA PELA ISO 9001:2008

SECRETARIA DE ESTADO DE  
PLANEJAMENTO,  
DESENVOLVIMENTO, CIÊNCIA,  
TECNOLOGIA E INovação



GOVERNO DO ESTADO DO  
**AMAZONAS**

Laboratório de Sistemas Inteligentes  
Escola Superior de Tecnologia  
Universidade do Estado do Amazonas



## *Detecção Inteligente de Retinopatia Diabética com Redes Neurais Convolucionais Profundas*

**Diego Lucena de Medeiros & Elloá B. Guedes**

{*dldm.eng18, ebgcosta*}@uea.edu.br

*XXXIX Simpósio Brasileiro de Telecomunicações e Processamento de Sinais (SBrT 2021)*